PREPROCESAMIENTO

1. Cargamos el Excel en KNIME

#	RowID	car_id	model	year	engine_si...	horsepow...	fuel_type	transmiss...	drivetrain	mileage_...	fuel_cons...	co2_emis...	price_usd	doors	
		Number (I...	String	Number (I...	Number (...	Number (I...	String	String	String	Number (I...	Number (...	Number (I...	Number (I...	Number (I...	
1	Row0	1	X5	2016	4	272	diesel	automatic	AWD	74655	8.9	196	66756	5	5
2	Row1	2	1 Series	2022	2.6	218	petrol	automatic	FWD	23469	8.4	190	26867	3	4
3	Row2	3	X1	2012	2.2	240	petrol	automatic	FWD	123273	7.8	174	31313	5	5
4	Row3	4	X5	2022	3.8	316	diesel	?	AWD	33064	9.4	192	81594	5	5
5	Row4	5	7 Series	2023	3.1	294	petrol	automatic	RWD	23926	?	204	104105	4	5
6	Row5	6	X1	2010	1.9	190	diesel	automatic	AWD	182375	5.7	112	18615	5	5
7	Row6	7	5 Series	2008	4.2	383	petrol	automatic	AWD	274131	10.7	222	27173	4	5
8	Row7	8	1 Series	2017	1.7	230	petrol	automatic	RWD	73728	7.3	148	22374	5	5
9	Row8	9	X1	2013	1.8	171	petrol	automatic	AWD	170822	7.6	166	24335	5	5
10	Row9	10	i3	2012	0	156	electric	automatic	RWD	166379	0	0	19182	5	4
11	Row10	11	1 Series	2016	3	276	petrol	automatic	RWD	145961	9.4	?	14587	5	4
12	Row11	12	3 Series	2019	2	169	hybrid	automatic	AWD	66059	4.6	104	37881	4	5
13	Row12	13	X5	2021	3.2	267	diesel	automatic	AWD	52609	8.4	197	76525	5	5
14	Row13	14	X3	2024	3.2	233	diesel	automatic	AWD	14470	?	164	62303	5	5
15	Row14	15	X3	2023	2.4	183	petrol	?	RWD	32107	9.9	?	54498	5	5

2. Utilizamos el nodo Statistics para hacer un análisis rápido de los datos.

#	RowID	Column	Min	Max	Mean	Std. deviati...	Variance	Skewness	Kurtosis	Overall sum	No. missin...	No. NaNs	No. +oos	No. -oos	Median	Row count	Histogram
		String	Number (Fl...	Number (Fl...	Number (Fl...	Number (Fl...	Number (Fl...	Number (Fl...	Number (Fl...	Number (Fl...	Number (Int...	Number (Int...	Number (Int...	Number (Int...	Number (Fl...	Number (Int...	Image (SVG)
1	car_id	car_id	1	10,000	5,000.5	2,886.896	8,334,166.667	0	-1.2	50,005,000	0	0	0	0	?	10000	
2	year	year	2,005	2,024	2,016.382	5.442	29.621	-0.393	-0.944	20,163,817	0	0	0	0	?	10000	
3	engine	engine_size	0	5	2.485	1.201	1.442	-0.706	0.03	24,241.8	243	0	0	0	?	10000	
4	horsep	horsepower	120	700	269.949	80.687	6,510.456	0.914	1.427	2,699,486	0	0	0	0	?	10000	
5	mileag	mileage_km	0	300,000	112,364.794	86,335.776	7,453,866,215.61	0.618	-0.626	1,123,647,940	0	0	0	0	?	10000	
6	fuel_co	fuel_consumptio	0	12.9	6.569	3.022	9.132	-0.989	0.327	64,073.9	246	0	0	0	?	10000	
7	co2_er	co2_emissions_c	0	297	144.106	67.02	4,491.662	-0.941	0.249	1,408,633	225	0	0	0	?	10000	
8	price_u	price_usd	2,640	225,487	50,861.399	31,121.966	969,199,329.623	1.501	3.21	508,613,988	0	0	0	0	?	10000	
9	doors	doors	2	5	4.32	0.775	0.6	-1.22	1.46	43,199	0	0	0	0	?	10000	
10	seats	seats	2	5	4.726	0.691	0.478	-2.953	8.42	47,256	0	0	0	0	?	10000	
11	owner_	owner_count	0	5	1.943	1.378	1.9	0.412	-0.648	18,935	255	0	0	0	?	10000	

Podemos ver en varias columnas hay valores muy pequeños como la columna engine_size, doors, seats y owner_count y otras columnas que tienen valores pequeños también, pero pueden alcanzar valores grandes como el year, mileage_km, price_usd.

3. Viendo el resultado Statistics vemos que tenemos varias columnas null como engine_size, fuel_consumption, co2_emissions y owner_count.

El ajuste que hemos seguido es el siguiente para los nulos.

- Number: Mean → Hacer la media de los valores numéricos
- String: Remove Row → En los valores string queremos eliminar esas filas, para no alterar el resto de valores que si son correctos.

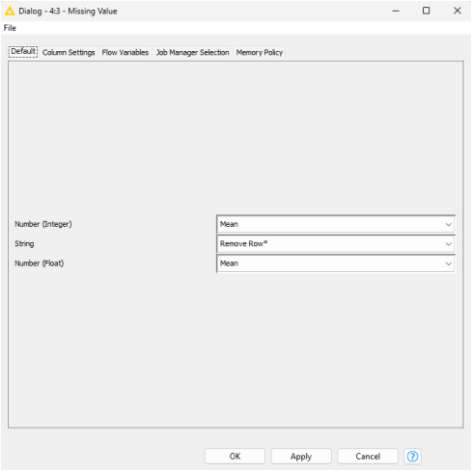

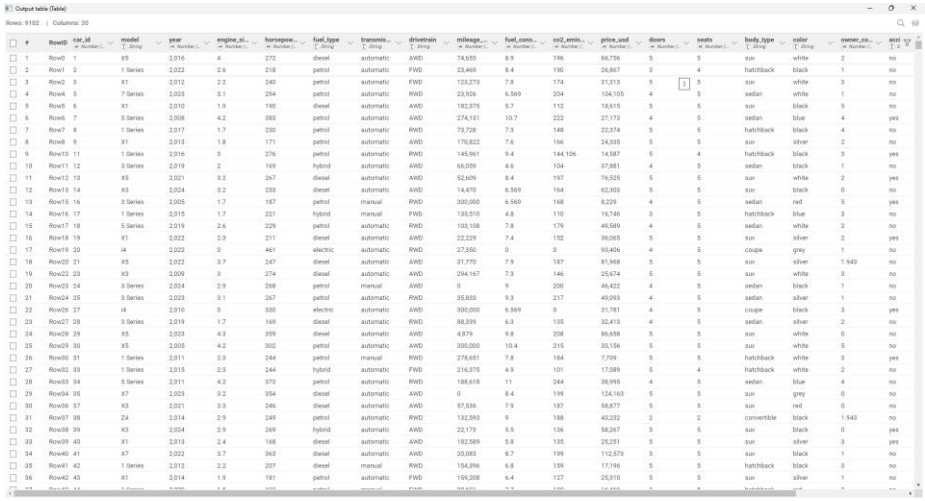

4. Ahora seguimos preprocesando los datos y para ello aplicamos un normalizer para las variables numéricas necesarias de normalizar.

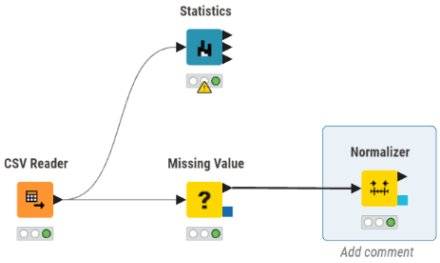

Incluimos las columnas de variables numéricas a normalizar

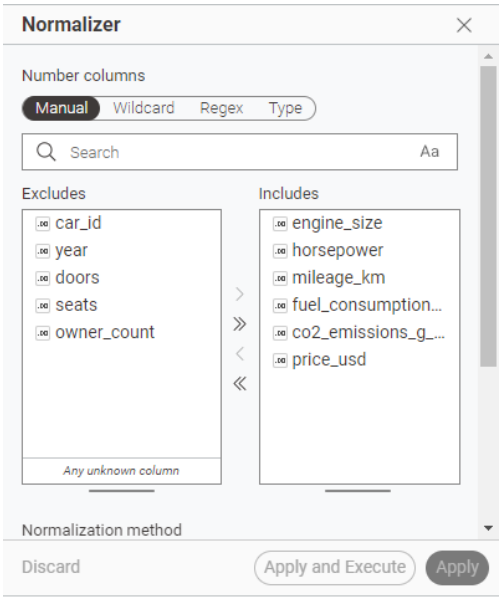

5. Creamos una columna nueva, en nuestro caso vemos que los años son muy importante en los coches, por funcionamiento o por precio, por tanto y como tenemos los años de cada coche vamos a crear una variable llamada antigüedad que nos cuenta cuantos años tiene cada coche.
Para ello utilizamos el nodo Math Formula.

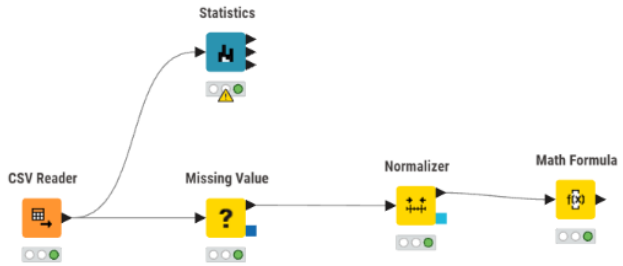

Restamos el año actual, menos el año del coche y en el nombre de la columna la llamamos "antigüedad"

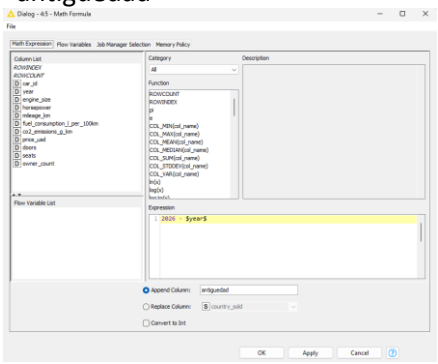

Ejecutamos y ahí tenemos la columna

antiguedad Number (...
10
4
14
3
16
18
9
13
10
7
5
2
21
11
7
4
4
4
17
2
3
16
7
3
21
15
11
15
3
5
12
2
13
4
14
12

CLASIFICACIÓN

1. Me gustaría determinar si el precio de un coche incluye en la calidad, para ello creamos una nueva columna llamada calidad, utilizando un rule engine.

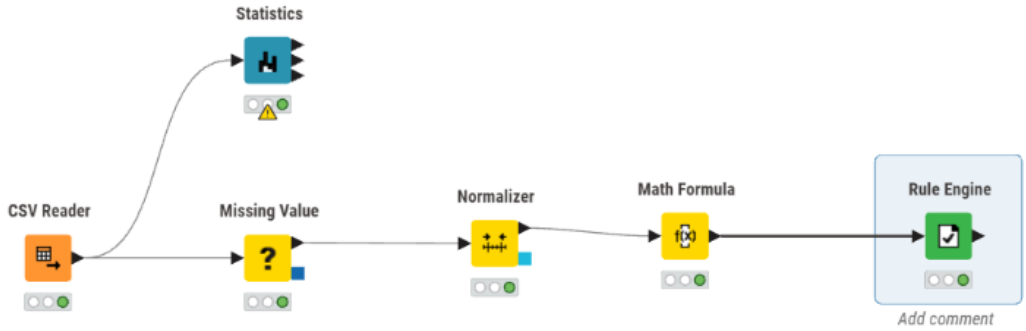

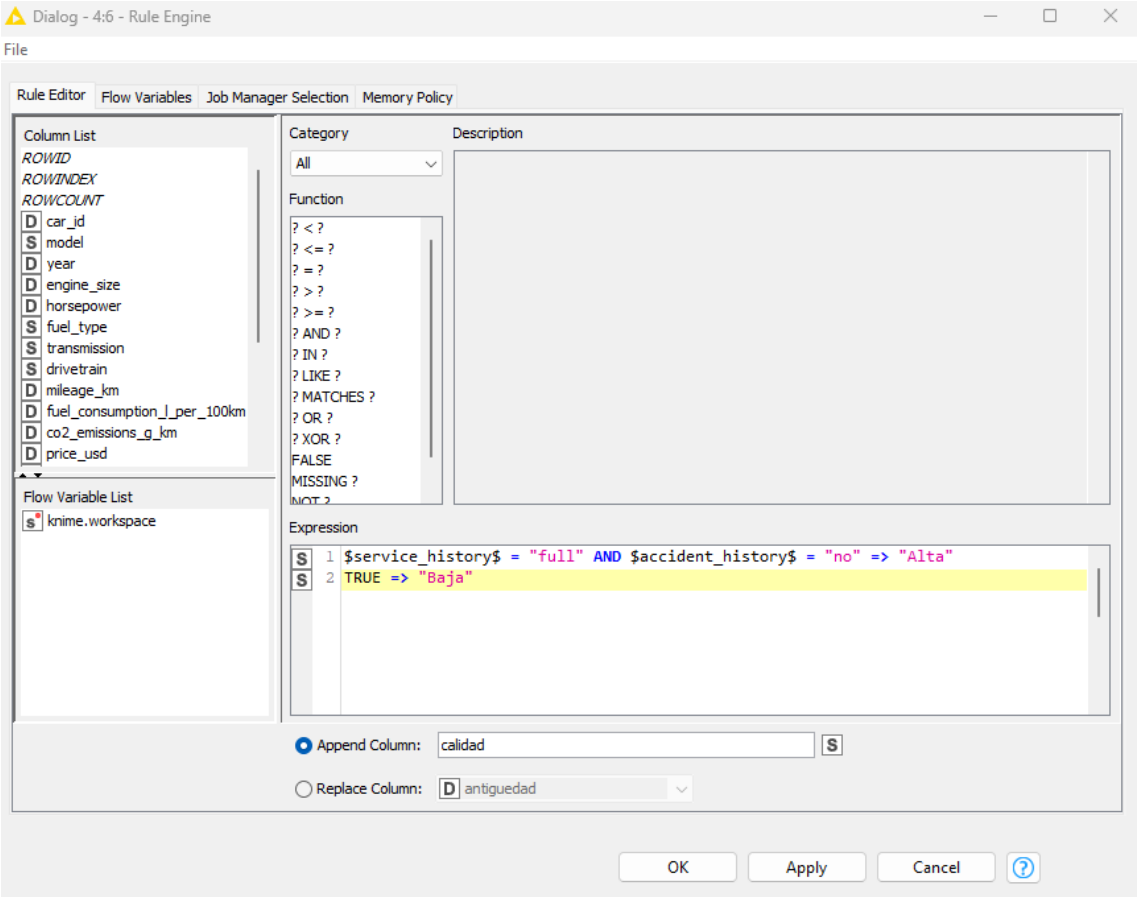

calidad String
Baja
Baja
Alta
Alta
Baja
Baja
Baja
Alta
Baja
Alta
Baja
Baja

2. Ahora vamos a utilizar el table partitioner para dividir los datos en un 80% - 20%

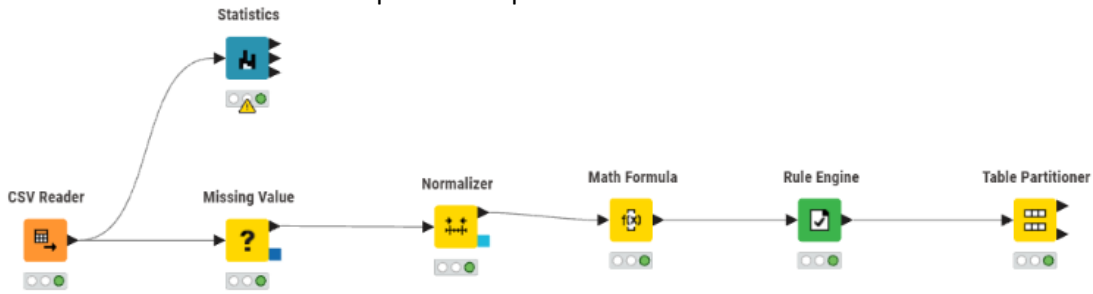

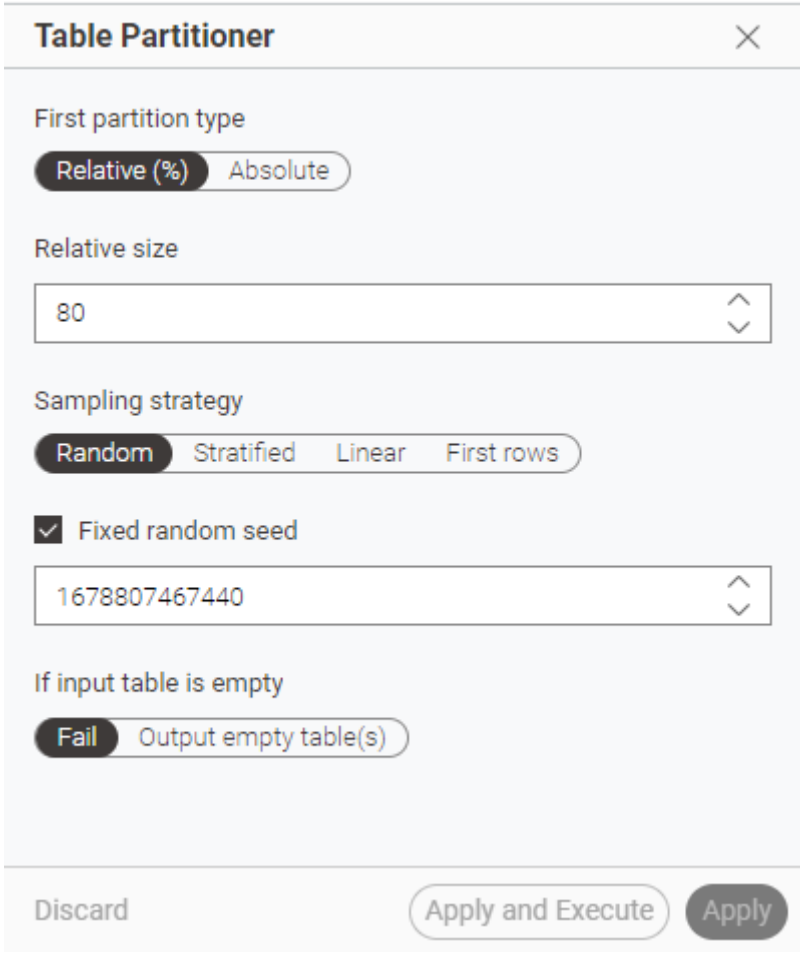

3. Utilizamos el nodo Decision Tree Learner para aprender de los datos, para ello seleccionamos la columna de calidad

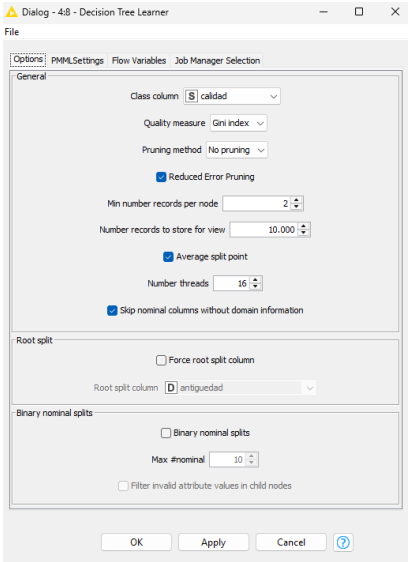

4. Ahora vamos a conectar la segunda partición, para ello utilizamos el decision tree predictor con la siguiente configuración.

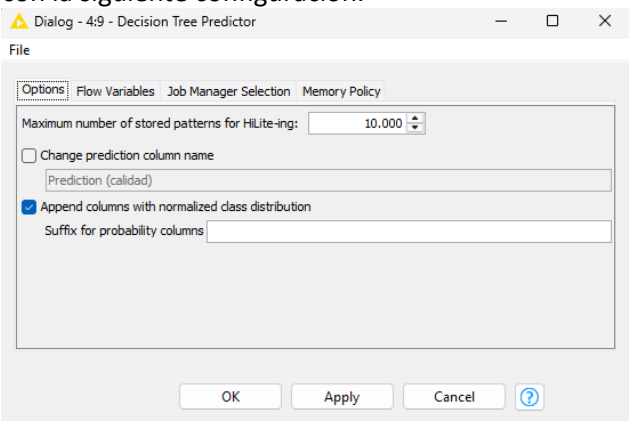

5. Por último añadimos el scorer para visualizar los datos después el procesado con la siguiente configuración.

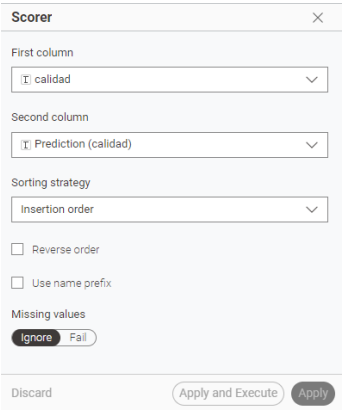

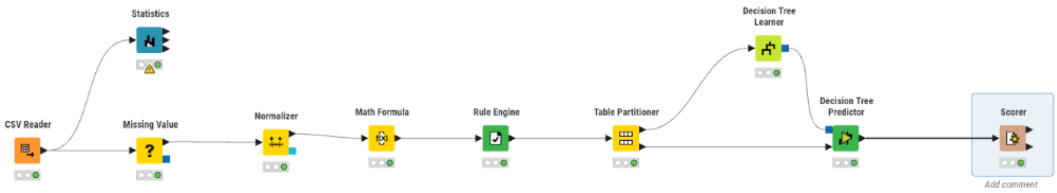

Que variable intentas predecir: La variable objetivo es calidad, la que clasifica los coches en alta o baja según el historial de mantenimiento

Que variables influyen más: Las variables más importantes son antigüedad, precio y kilometraje.

Si el modelo funciona bien o no: El modelo tiene una precisión del 90%

REGRESION

1. La variable numérica que vamos a elegir el price_usd puesto que en nuestro dataSet de coches es una de las variables más importante, puesto que es lo que buscas a la hora de comprar o estudiar un coche, el precio que tiene. Además, esta variable está relacionada con otras variables que hemos utilizado antes como la antigüedad.

2. Aplicamos el nodo GroupBy seleccionando varias variables como model, body_type y fuel_type.

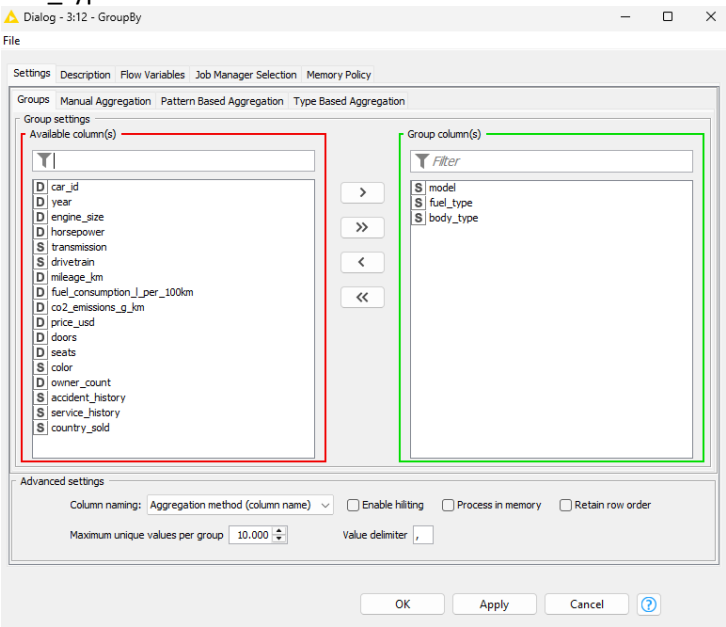

En la pestaña Manual Aggregation añadimos las columnas price_usd, horsepower.

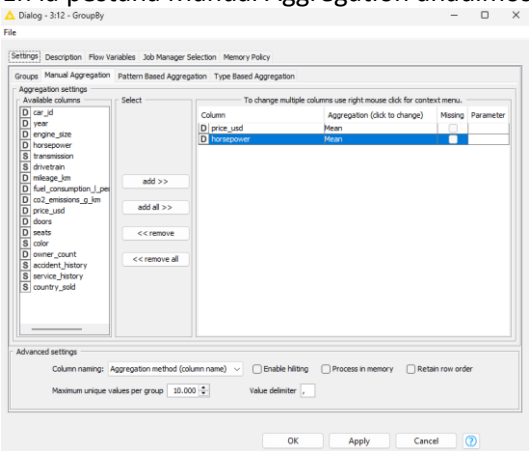

3. Como tengo variables categóricas de tipo String , vamos a crear con el nodo One To Many nuevas columnas donde vamos a transformar en variables categóricas de 1 y 0. En nuestro caso aplicamos las columnas numéricas model, fuel_type y body_type.

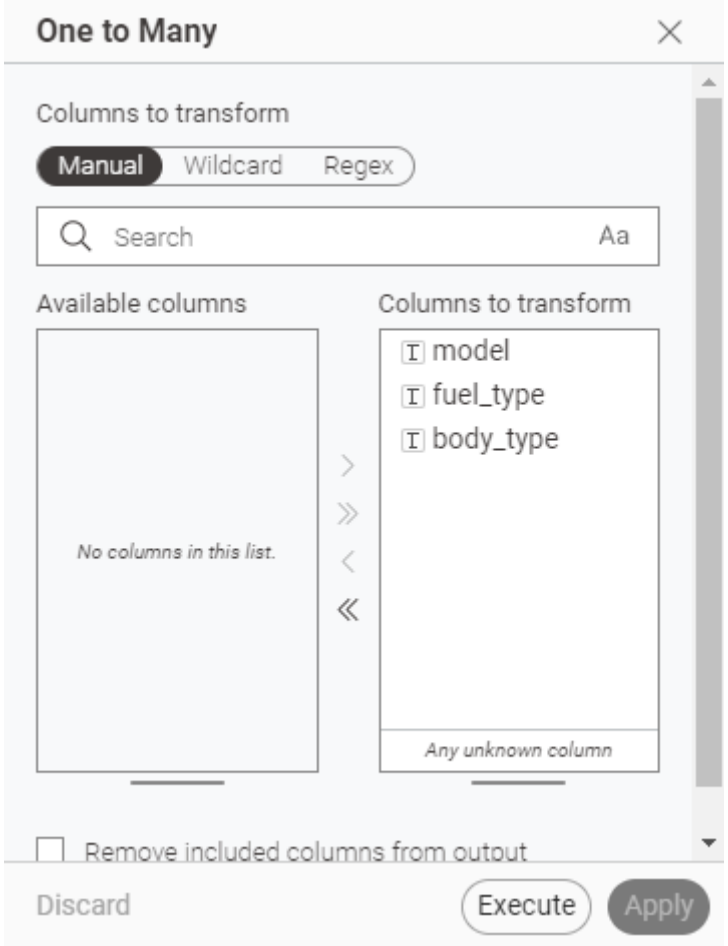

4. Aplicamos otra vez el table partitioner con los mismos datos de antes.

5. Aplicamos un Linnear Regresion Learner cuya columna principal sería mean(price_usd) puesto que el nodo Group By ya calculé la media y escojemos esta columna por q queremos calcular el valor económico del coche.

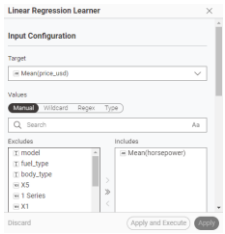

6. Creamos el regression predictor y el numeric scorer ajustando la columna de referencia como mean(price_usd) y la columna predicted colum prediction(Mean(price_usd)) y nos da la siguiente solución.

#	RowID	Prediction (Mean(price_usd)) Number (Float)
1	R^2	0.423
2	mean absolute error	14,274.617
3	mean squared error	271,106,967.207
4	root mean squared error	16,465.326
5	mean signed difference	-6,492.807
6	mean absolute percentage error	0.302
7	adjusted R^2	0.423

CLUSTERING

1. Aplicamos el missing value de principio de cada apartado

2. Aplicamos un rule engine y creamos una columna nueva llamada modelos y con ello dividimos los coches en SUV, Turismo, Deportivo y otro

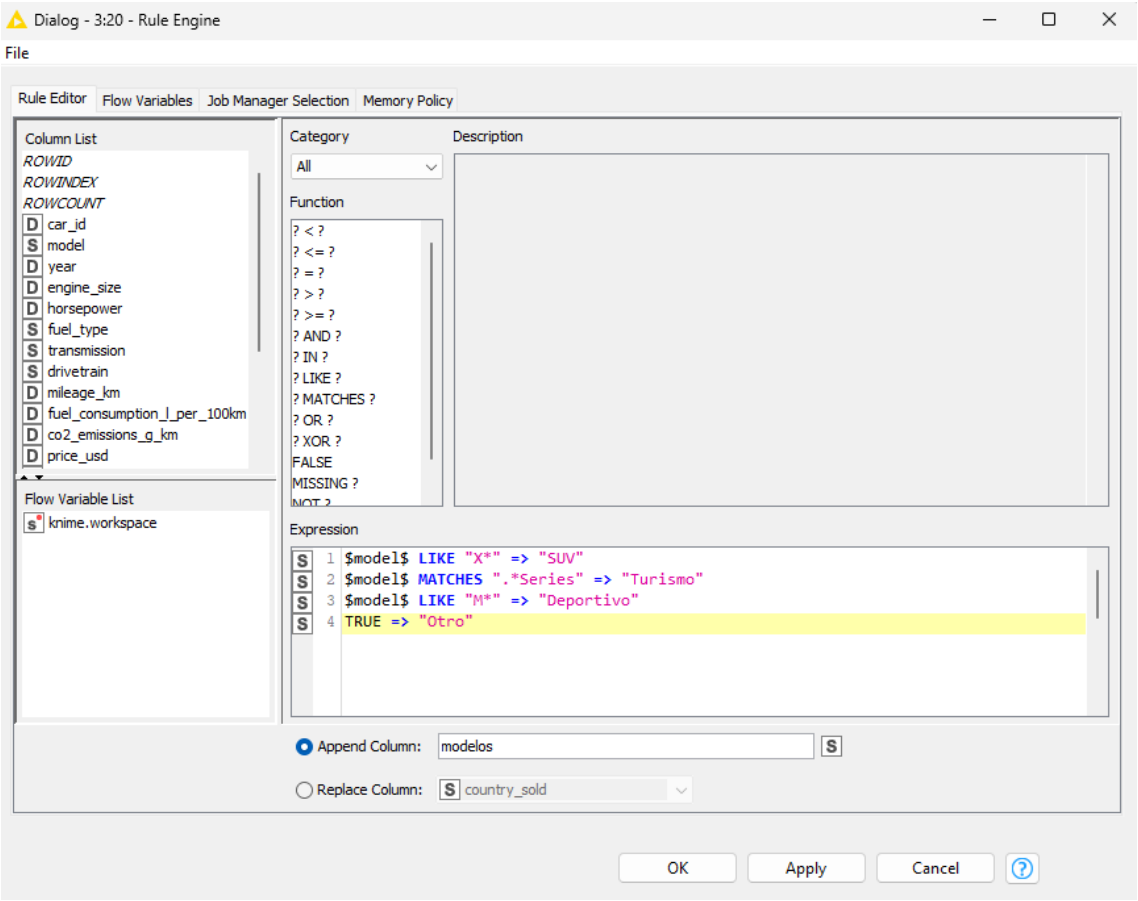

3. Aplicamos un group by para agrupar nuestros datos.

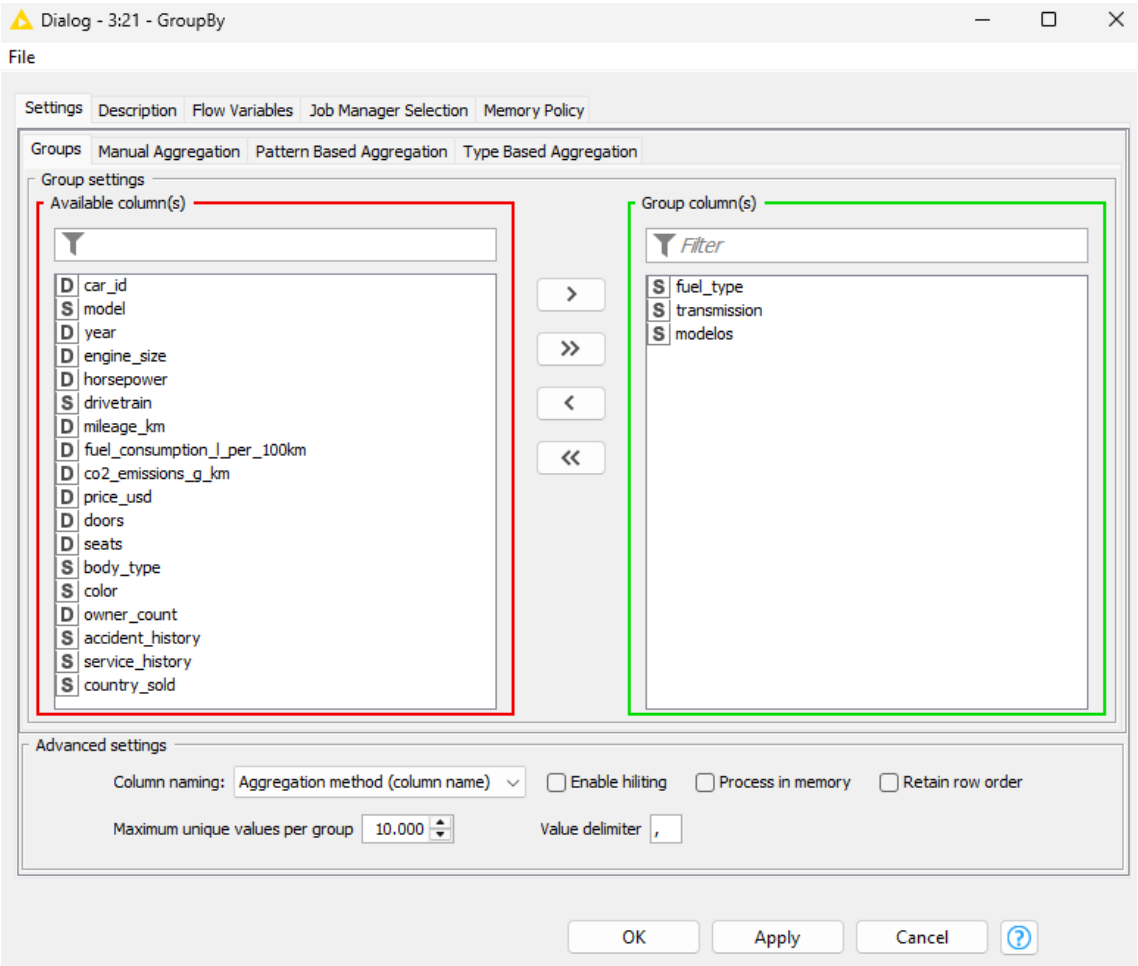
Dialog - 3:21 - GroupBy
File
Settings
Description
Flow Variables
Job Manager Selection
Memory Policy
Groups
Manual Aggregation
Pattern Based Aggregation
Type Based Aggregation
Group settings
Available column(s)
D car_id
S model
D year
D engine_size
D horsepower
S drivetrain
D mileage_km
D fuel_consumption_l_per_100km
D co2_emissions_g_km
D price_usd
D doors
D seats
S body_type
S color
D owner_count
S accident_history
S service_history
S country_sold
Group column(s)
Filter
S fuel_type
S transmission
S modelos
Advanced settings
Column naming:
Aggregation method (column name)
Enable hiliting
Process in memory
Retain row order
Maximum unique values per group
10.000
Value delimiter
,
OK
Apply
Cancel

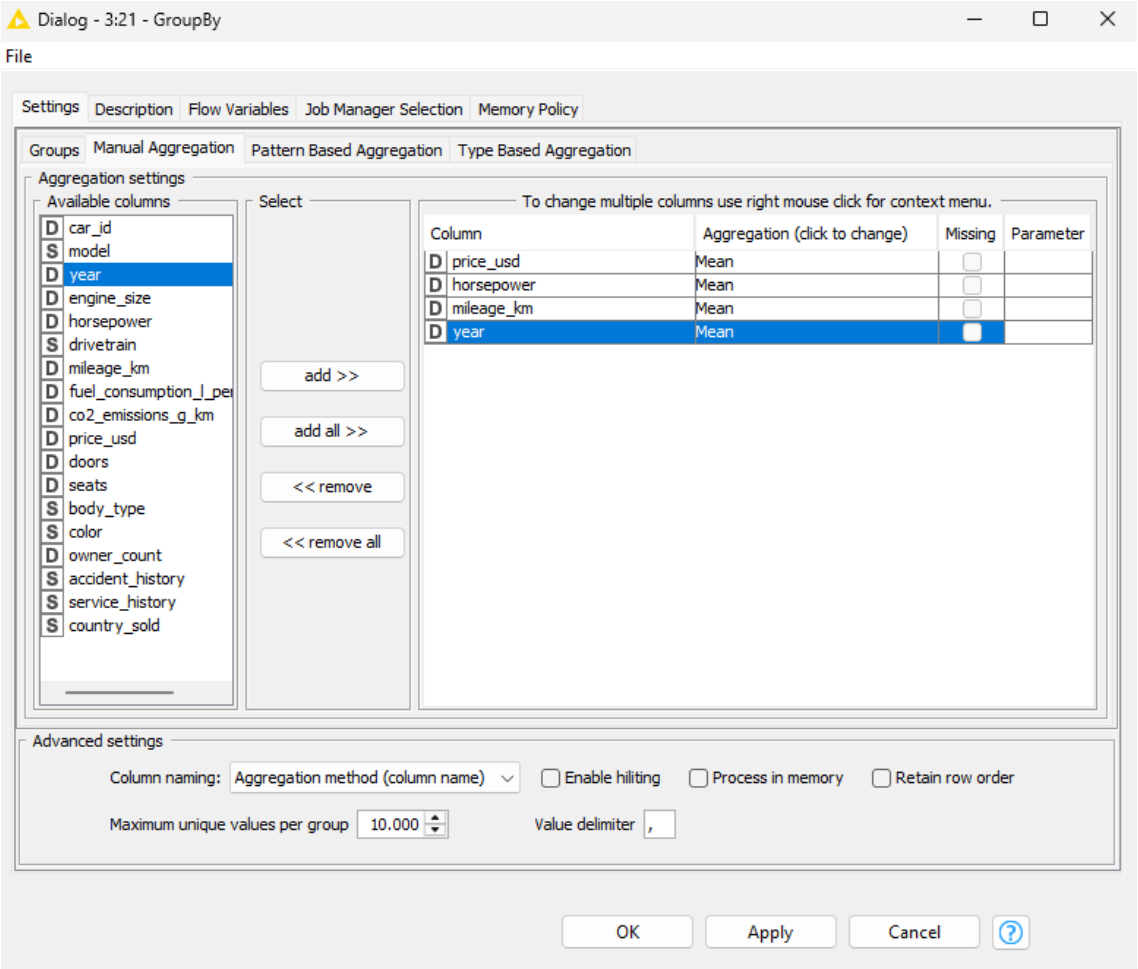

4. Ahora realizamos un pivot para reaorganizar la tabla para poder comparar los datos.
En la pestaña grupos seleccionamos la variable modelos para que cada fila sea un tipo de coche distinto.

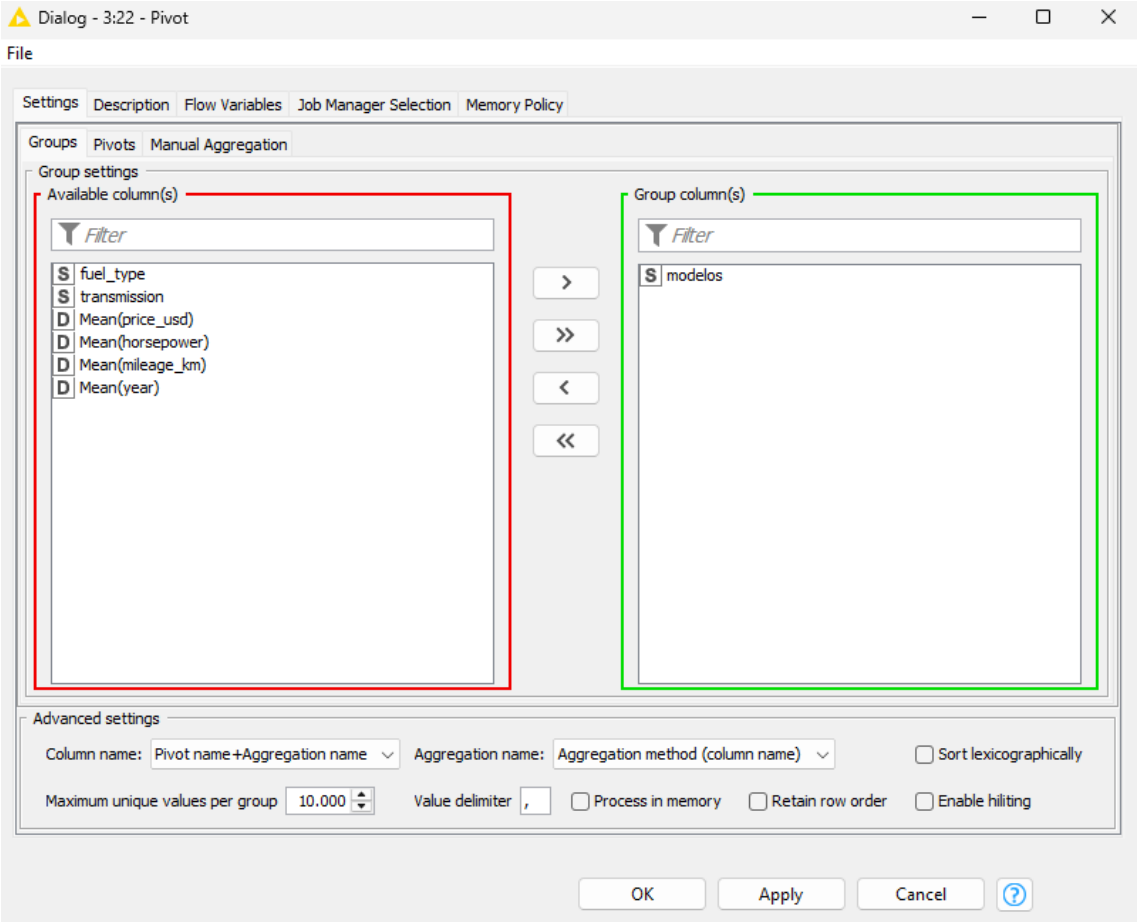

En la pestaña pivots seleccionamos fuel_type para ajustar por combustible.

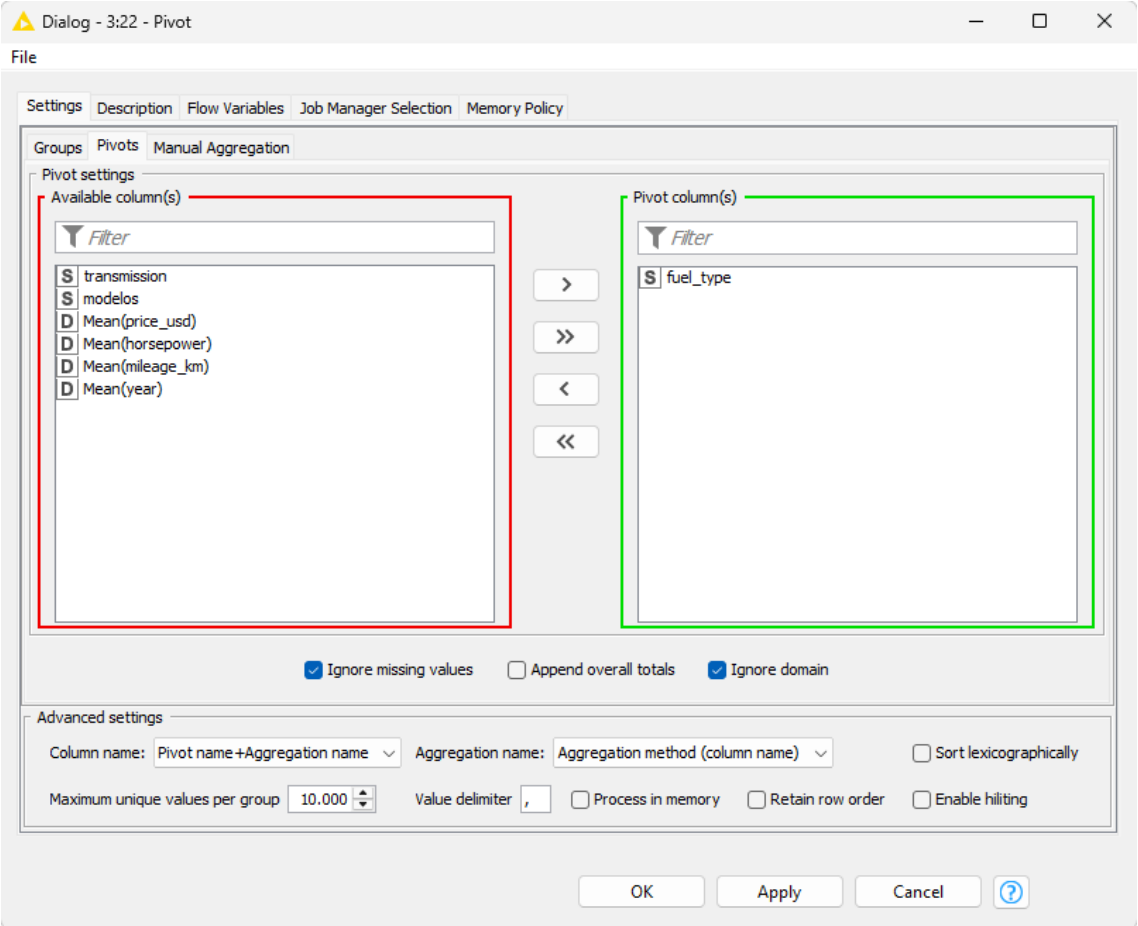

En la pestaña manual agregation elegimos los datos que rellenarán la tabla seleccionando los promedios. Y la solucion es la siguiente

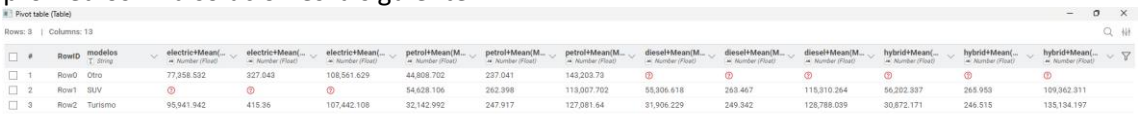

#	RowID	modelos	electric+Mean(...	electric+Mean(...	electric+Mean(...	petrol+Mean(M...	petrol+Mean(M...	petrol+Mean(M...	diesel+Mean(M...	diesel+Mean(M...	diesel+Mean(M...	hybrid+Mean(...	hybrid+Mean(...	hybrid+Mean(...
1	Row0	Otro	77,358.532	327.043	108,561.629	44,808.702	237.041	143,203.73	?	?	?	?	?	?
2	Row1	SUV	?	?	?	54,628.106	262.398	113,007.702	55,306.618	268.467	115,310.264	56,202.337	265.953	109,362.311
3	Row2	Turismo	95,941.942	415.36	107,442.108	32,142.992	247.917	127,081.64	31,906.229	249.342	128,788.039	30,872.171	246.515	135,134.197

Como vemos que tenemos valores nulos tenemos que tratarlos con el nodo missing values

5. Aplicamos un nodo missing value para cambiar todos esos valores nulos por valores reales. Cambiamos el valor a 0 de los nulos.

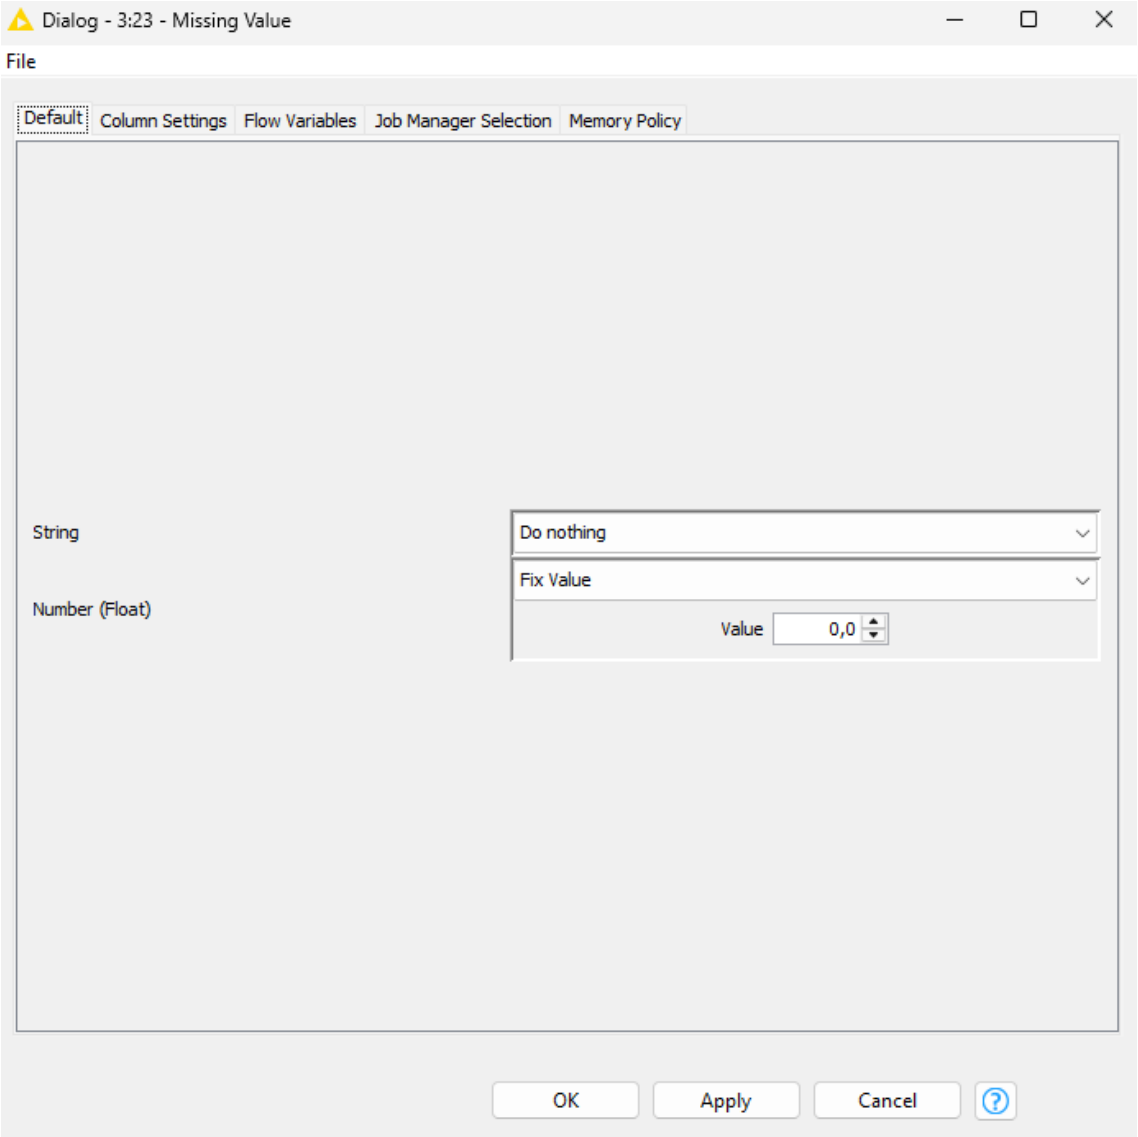

6. Aplicamos un normalices para ajustar la diferencia de los nuemor, puesto que tenemos números desde 0 hasta 60000.
Añadimos todas las columnas y normalizamos de 0 a 1

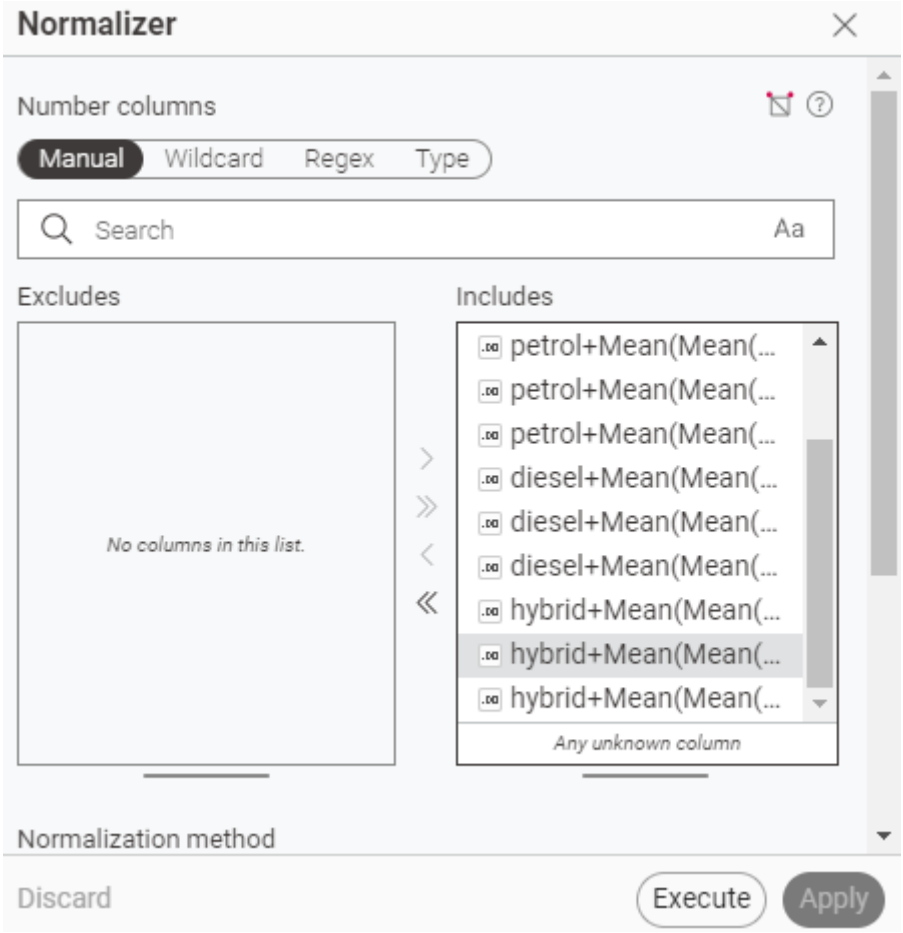

7. Aplicamos el Kmeans con los valores por defecto con un número de tres clusters

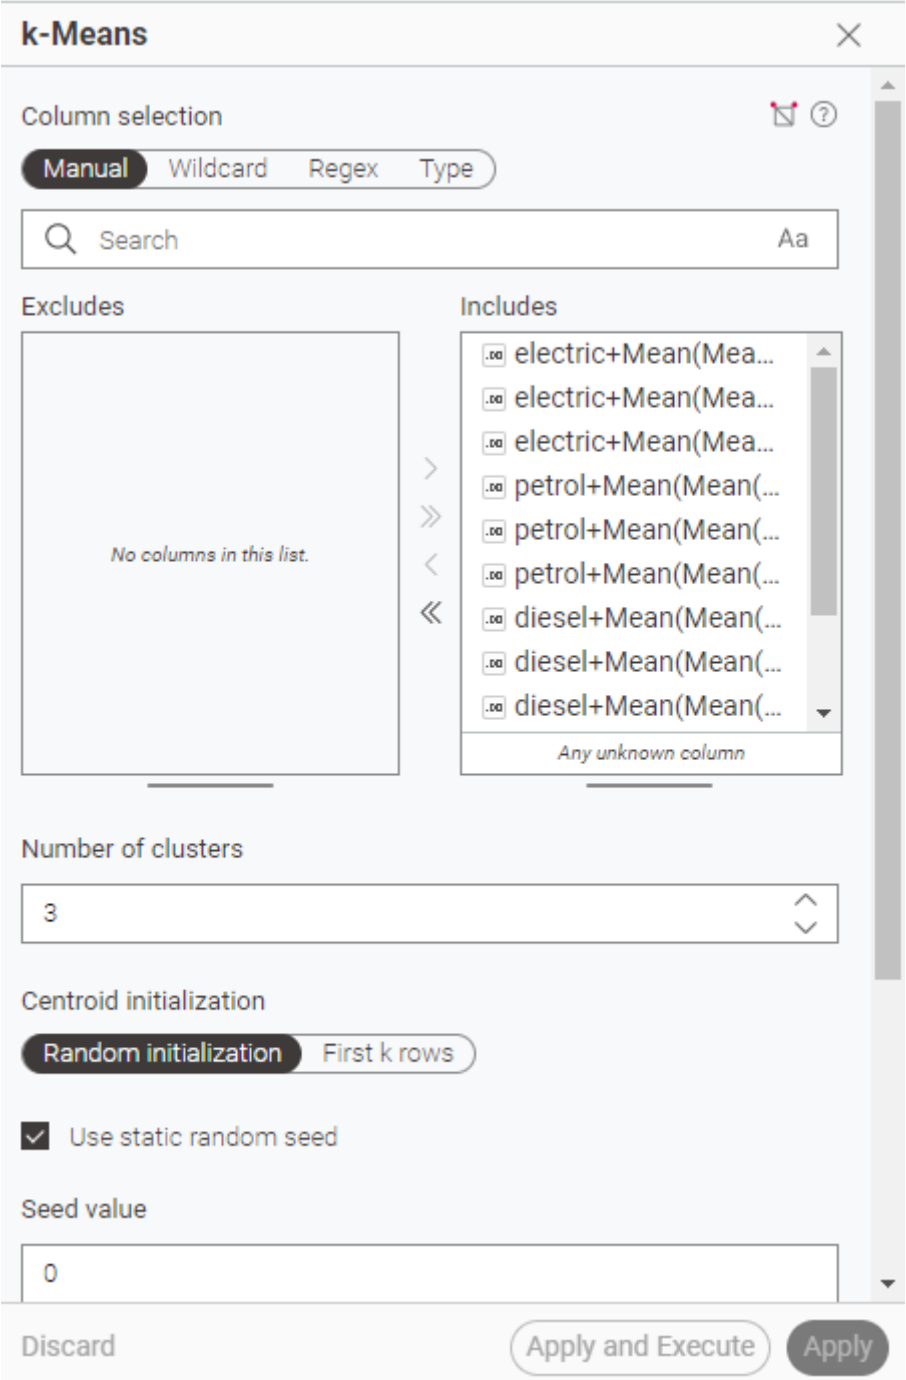

Y la solución final de momento tiene esta forma.

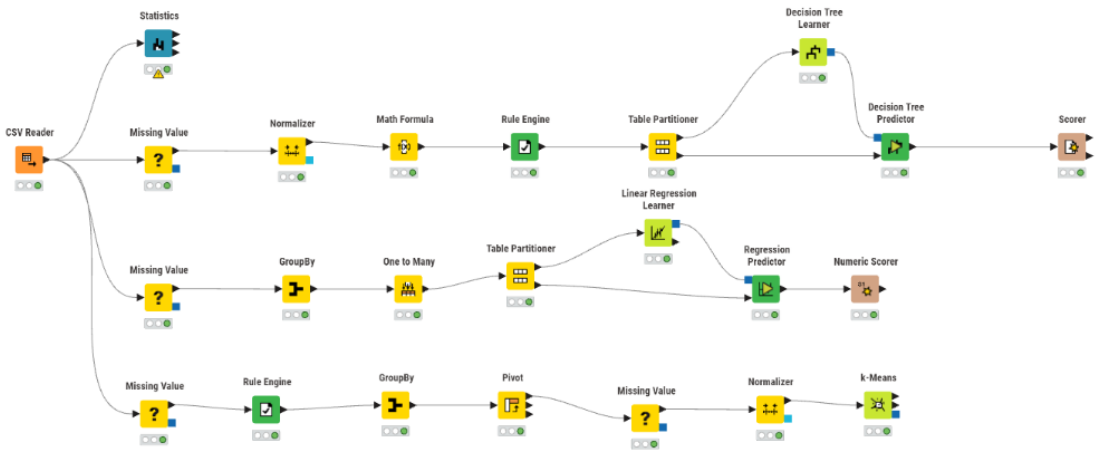

Justificación del número de clústers (k): Elegir 3 clústeres nos permite maximizar la diferencia entre los grupos sin complicar demasiado el modelo.

Descripción de cada grupo:

- **Grupo 0 - "Especialista Diésel":** Coches exclusivamente Diésel, con kilometraje medio-alto (**160k km**) y precios de entrada (**$38k**). Mercado de segunda mano funcional.

- **Grupo 1 - "Estándar Gasolina":** Coches exclusivamente de Gasolina. Son los más nuevos y con menos uso (**67k km**), con un precio equilibrado (**$44k**). El corazón del mercado BMW.

- **Grupo 2 - "Híbrido/Premium":** El segmento de mayor valor. Mezcla coches Híbridos y de Gasolina potentes, con los precios más altos (**+$60k**) y muy pocos kilómetros.

La diferencia principal es la **especialización tecnológica**: el modelo ha separado los coches por su tipo de motor (**Diésel vs Gasolina vs Híbrido**)

ASOCIACIÓN

1. Usamos 3 rule engine para transformar las variables numéricas en categóricas, en nuestro caso vamos a utilizar las variables: petrol+Mean(Mean(price_usd)), diesel+Mean(Mean(mileage_km)), electric+Mean(Mean(horsepower))

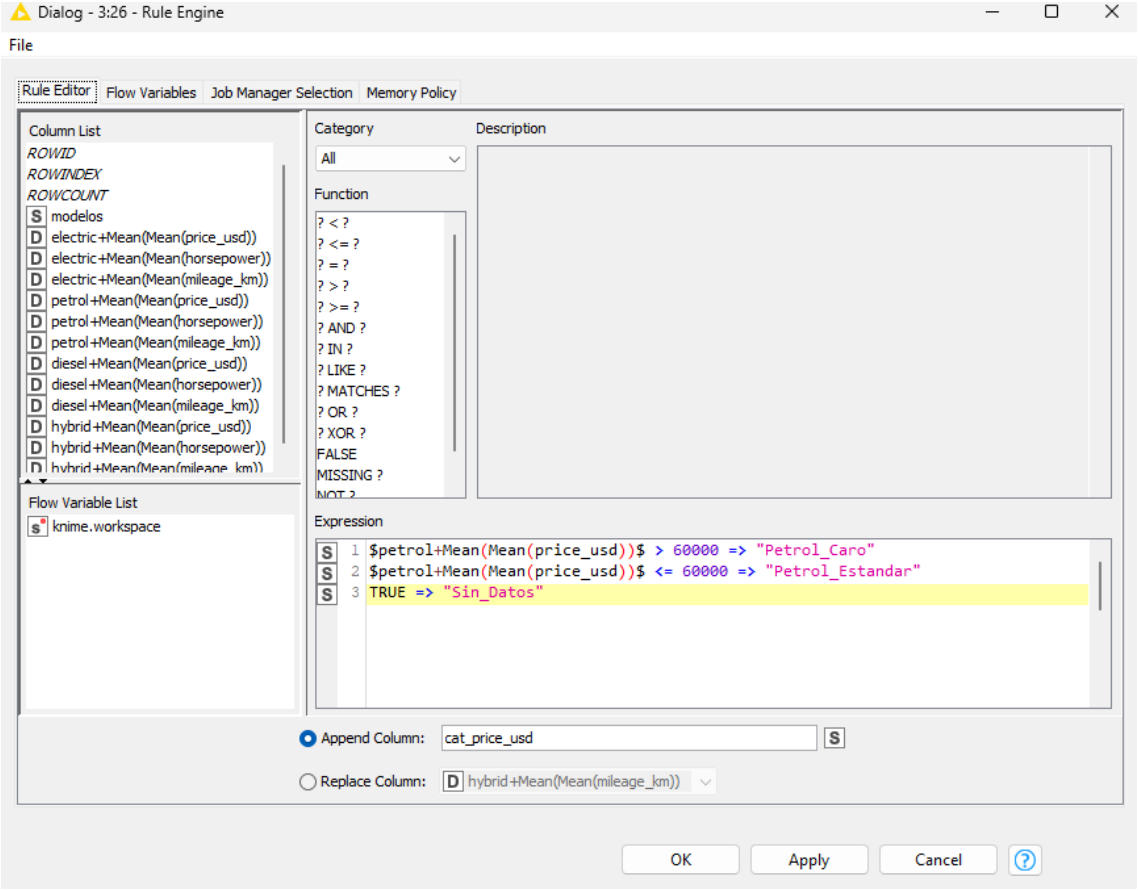

Dialog - 3:27 - Rule Engine

File

Rule Editor | Flow Variables | Job Manager Selection | Memory Policy

Column List

ROWID
ROWINDEX
ROWCOUNT
S modelos
D electric+Mean(Mean(price_usd))
D electric+Mean(Mean(horsepower))
D electric+Mean(Mean(mileage_km))
D petrol+Mean(Mean(price_usd))
D petrol+Mean(Mean(horsepower))
D petrol+Mean(Mean(mileage_km))
D diesel+Mean(Mean(price_usd))
D diesel+Mean(Mean(horsepower))
D diesel+Mean(Mean(mileage_km))
D hybrid+Mean(Mean(price_usd))
D hybrid+Mean(Mean(horsepower))

Flow Variable List

knime.workspace

Category: All

Function

? < ?
? <= ?
? = ?
? > ?
? >= ?
? AND ?
? IN ?
? LIKE ?
? MATCHES ?
? OR ?
? XOR ?
FALSE
MISSING ?
NOT ?

Description

Expression

```
1 $diesel+Mean(Mean(mileage_km))$ > 150000 => "Diesel_Muy_Usado"
2 $diesel+Mean(Mean(mileage_km))$ <= 150000 => "Diesel_Poco_Usado"
3 TRUE => "Sin_Datos"
```

Append Column: cat_mileage_km

Replace Column: cat_price_usd

OK | Apply | Cancel

Dialog - 3:28 - Rule Engine

File

Rule Editor | Flow Variables | Job Manager Selection | Memory Policy

Column List

ROWID
ROWINDEX
ROWCOUNT
S modelos
D electric+Mean(Mean(price_usd)
D electric+Mean(Mean(horsepowe
D electric+Mean(Mean(mileage_kr
D petrol+Mean(Mean(price_usd))
D petrol+Mean(Mean(horsepower
D petrol+Mean(Mean(mileage_km
D diesel+Mean(Mean(price_usd))
D diesel+Mean(Mean(horsepower
D diesel+Mean(Mean(mileage_km
D hybrid+Mean(Mean(price_usd))

Flow Variable List

knime.workspace

Category: All

Function

? < ?
? <= ?
? = ?
? > ?
? >= ?
? AND ?
? IN ?
? LIKE ?
? MATCHES ?
? OR ?
? XOR ?
FALSE
MISSING ?
NOT ?

Description

Expression

```
1 $electric+Mean(Mean(horsepower))$ > 300 => "Electrico_Potente"
2 TRUE => "Otros_Motores"
```

Append Column: cat_horsepower

Replace Column: cat_mileage_km

OK | Apply | Cancel

2. Utilizamos un column filter seleccionando las columnas creadas en el paso anterior

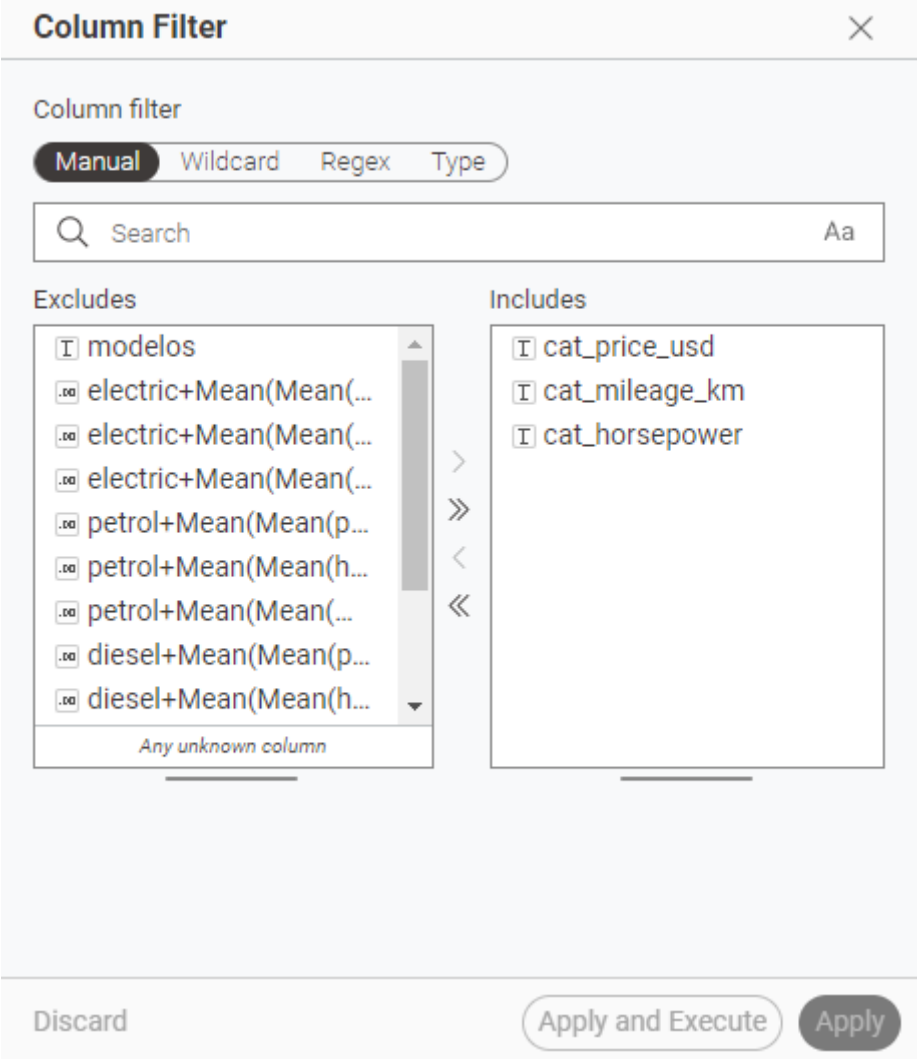

3. Utilizamos un One to Many para categorizar las variables cat_precio con valores entre 0 y 1

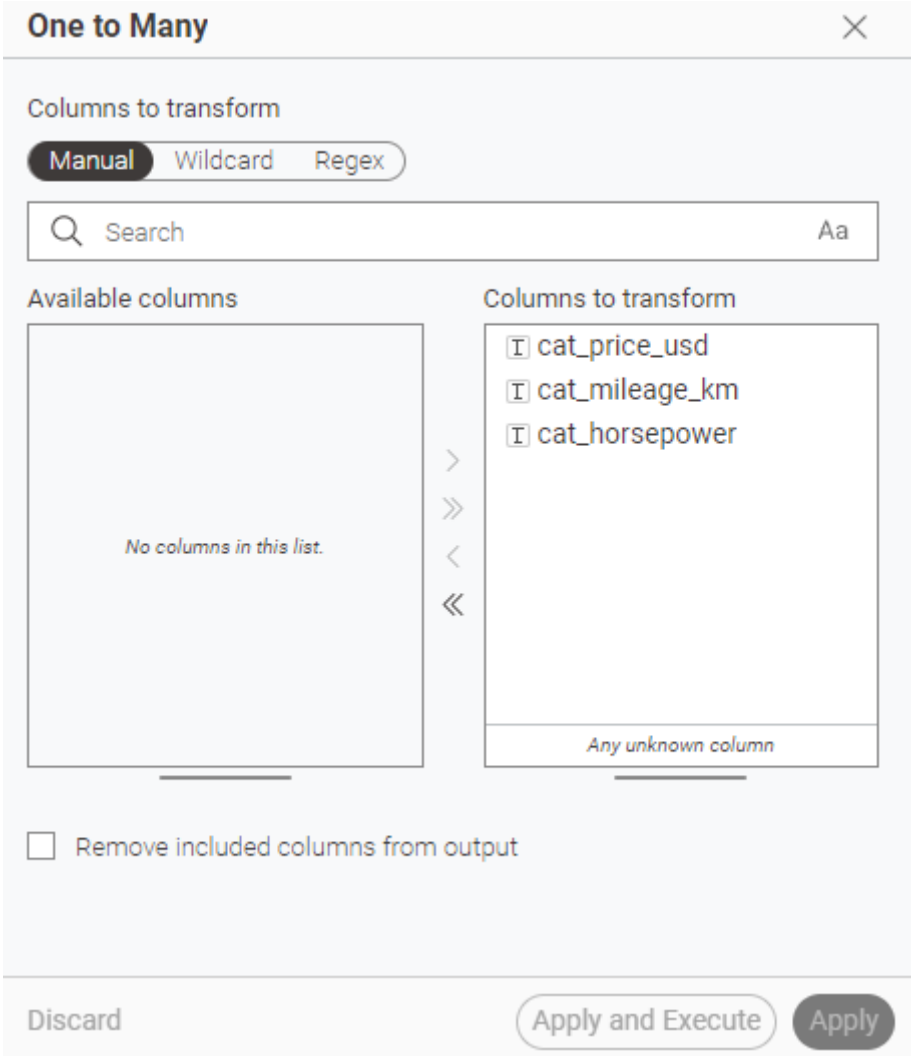

#	RowID	cat_price_usd String	cat_mileage_km String	cat_horsepower String	Petrol_Estandar Number (Integer)	Diesel_Poco_Usado Number (Integer)	Electrico_Potente Number (Integer)	Otros_Motores Number (Integer)
1	Row0	Petrol_Estandar	Diesel_Poco_Usado	Electrico_Potente	1	1	1	0
2	Row1	Petrol_Estandar	Diesel_Poco_Usado	Otros_Motores	1	1	0	1
3	Row2	Petrol_Estandar	Diesel_Poco_Usado	Electrico_Potente	1	1	1	0

4. Utilizamos un créate bit vector para transformar datos categóricos a un formato binario

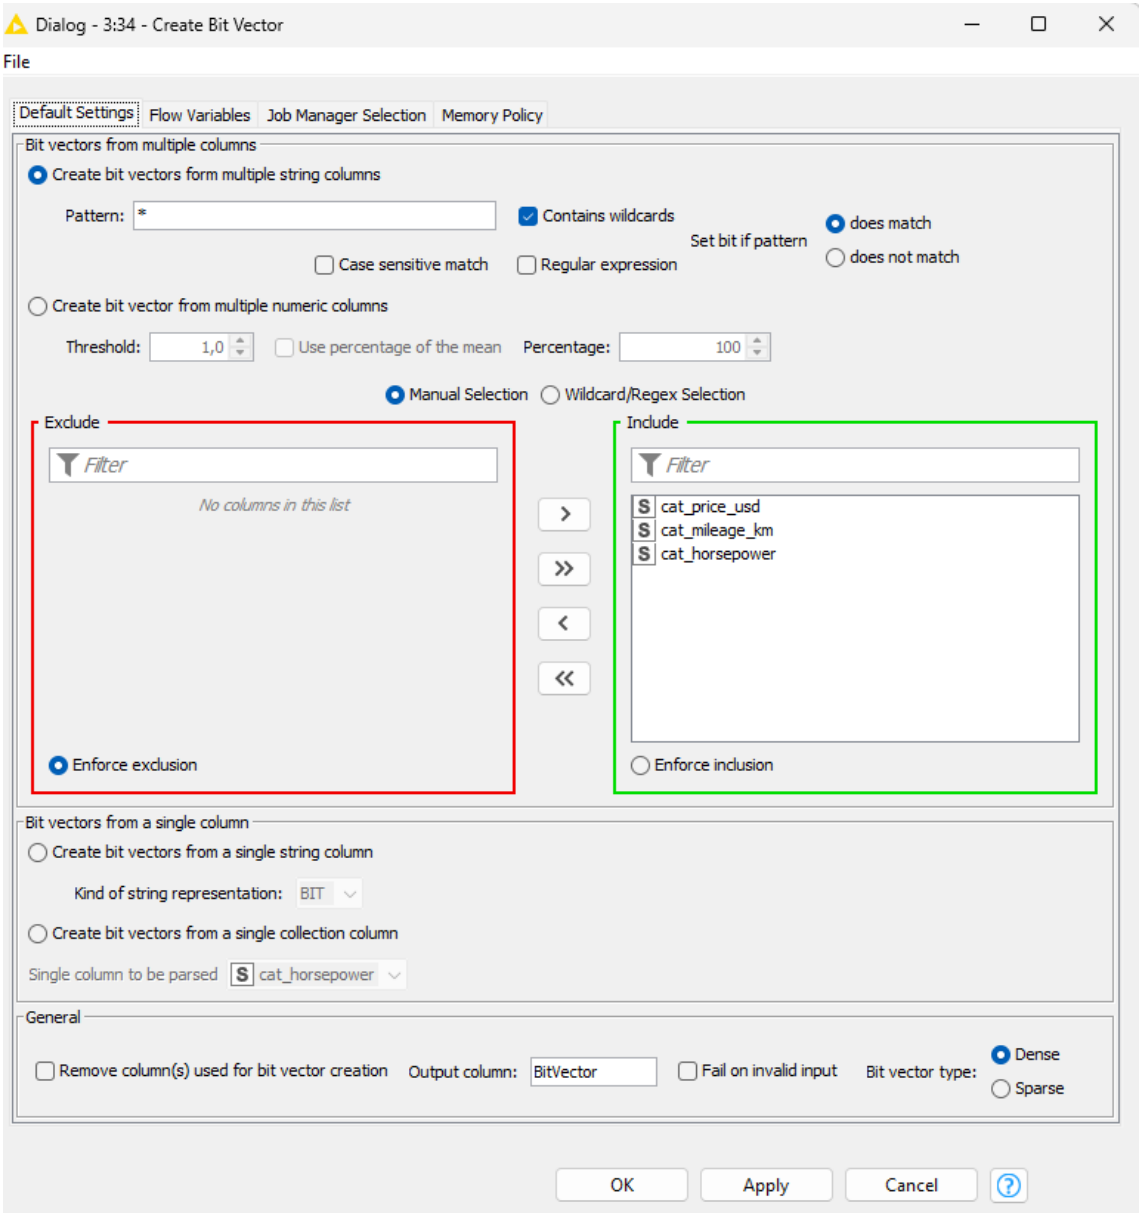

5. Utilizamos un association rule learner para descubrir los patrones.

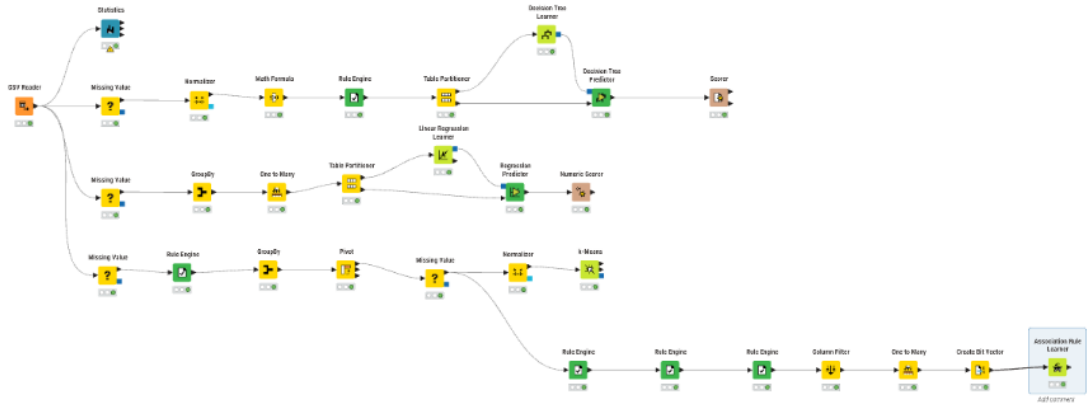

¿Qué patrones has detectado?: **cat_price_usd, cat_mileage_km y cat_horsepower tienen soporte = 1**, lo que significa que estas tres variables aparecen en el **100% de los registros**. Sin embargo, esto indica que las categorías dominantes en el dataset son:

- Precio: **Petrol_Estandar**
- Kilometraje: **Diesel_Poco_Usado**
- Motor: principalmente **Electrico_Potente**

El patrón más claro es que la combinación **Petrol_Estandar + Diesel_Poco_Usado** aparece de forma muy recurrente junto a distintos tipos de motor.

¿Qué has aprendido sobre el dataset?

- El dataset está **muy concentrado** en un perfil de coche concreto: precio estándar, poco kilometraje y motor eléctrico potente.
- Las columnas categóricas generadas por los Rule Engine funcionaron correctamente, produciendo 4 categorías de motor: Petrol_Estandar, Diesel_Poco_Usado, Electrico_Potente y Otros_Motores.
- El BitVector `111` que aparece en casi todas las filas confirma que **3 bits se activan simultáneamente** con mucha frecuencia.

¿Qué limitaciones tiene tu análisis?

- **Soporte = 1 en todo** sugiere que las categorías son demasiado amplias o que el dataset no tiene suficiente variedad, lo que hace que las reglas sean poco discriminativas.
- Solo se analizan **3 variables categorizadas**, perdiendo mucha información numérica del dataset original.
- Los **umbrales de los Rule Engine** (cómo se definieron las categorías de precio, km y potencia) condicionan completamente los resultados: si los rangos están mal definidos, las reglas de asociación no serán útiles.
- Con categorías tan dominantes, el algoritmo **no puede distinguir perfiles minoritarios** de coches que podrían ser igualmente interesantes.